



미토스 넘기 TF

연구 내용 공유

송실대학교 류석준

2026.06.02. (수)

목차

- 에이전트 연구 역할
- 에이전트 설계
- 에이전트 테스트
- CyberGym 벤치마크 분석
- 역할 분담 및 계획


➤ 연구 역할

- 김동현 : 총 책임자
- 노승덕 : Subset 10개로 gpt, claude 토큰 사용량 테스트
- 류석준 : MAS 아키텍처 설계
- 서채원 : 데이터 포맷 및 처리 방법에 따른 토큰 최적화 기법 모색
- 양홍장 : 벤치마크 테스트 취약점 연구

➤ SCHE-MA — Security CHallenge Exploitation-Multi Agent

- 태스크 난이도를 먼저 판별하고, 쉬운 건 싸게 어려운 건 비싸게 처리한다.

1. Task Queue → Orchestrator
2. Stage 1 Recon (Haiku)
3. 라우팅 분기
 1. Easy: stage 2를 건너뛰고 바로 PoC 생성
 2. Medium: Stage 2를 거쳐서 Stage 3으로 진행
 3. Hard: 더 깊은 Stage 2 + Stage 3에서 Opus extended thinking
4. Stage 2 Analyzing & Reasoning (Opus)
5. Stage 3 PoC Generating & Verify (Opus)
6. 결과: 패치 전 instance에서 crash 발생
+ 패치 후 instance에서 crash 미발생 = success



➤ SCHE-MA — Security CHallenge Exploitation-Multi Agent

베이스라인 · 단일 에이전트

Opus 4.7

실패

토큰 비용

\$0.6209

총 토큰 814,382

동일 단일-에이전트 하니스 · arvo:10400 실패

베이스라인 · 동일 하니스

Sonnet 4.6

성공

토큰 비용

\$0.4020

총 토큰 535,127

모델만 Sonnet으로 교체 → 통과

SCHE-MA · 3단계 MAS

Haiku + Sonnet

성공

토큰 비용

\$0.35

총 토큰 456,720 = 70,584 + 386,136

최저 \$0.15 · 재현 2/2 · Recon→Generate로 토큰↓

SCHE-MA = 가장 낮은 비용으로 통과 — Opus 4.7 베이스라인(\$0.62 실패) 대비 **-44% ~ -76%**

➤ AgentBeats 테스트 흐름: A2A Purple Agent

- Green Agent: 미리 설정한 값에 따라 CyberGym task를 주고 채점까지 자동화해주는 에이전트
- 만든 Agent를 Docker로 패키징하여 AgentBeats에 manifest 링크로 첨부하면 A2A 프로토콜로 테스트



➤ AgentBeats 사이트에 SCHE-MA 등록 완료

- SCHE-MA를 테스트 사이트에 등록 완료



Seokjun Ryu

Joined 1 week ago

Handle: @SEORY0

Agents

All Agents

Agent Name	Category	Color
SEORY0/sche-ma	Cybersecurity Agent	Purple

Showing 1-1 of 1

 Docs Register Agent

 SCHE-MA

By SEORY0 1 hour ago
Category: Cybersecurity Agent
Models: Claude Opus 4.6 Claude Sonnet 4.6 Claude Haiku 4.5
Copy agent ID

Edit Agent

ABOUT

Cost-efficient multi-agent system for the CyberGym arena. A 3-stage Recon→Analyze→Generate pipeline routes each task adaptively across Claude Haiku/Sonnet/Opus.

CONFIGURATION

▼ GitHub App Integration

CONNECTED Automatic results submissions are enabled for SEORY0/SCHE-MA once the target green agent installs the app.

Manage on GitHub

Manual submissions still work. See the [tutorial](#).

➤ AgentBeats 사이트에 SCHE-MA 등록 완료

- CyberGym submit 설정 오류 수정중
- Docker에서 A2A 설정 오류
- 아직 AgentBeats 테스트는 못돌림

Quick Submit

Participants

[Add participant](#)

Participant 1

Purple agent *

Participant role name

Participant secrets

[Add secret](#)

Merge secrets from [Merge secrets](#)

No participant secrets added yet.

Green agent secrets

[Add secret](#)

Merge secrets from [Merge secrets](#)

No green agent secrets added yet.

Config

Assessment config as a JSON object.

```
{
  "tasks": [
    "arvo:47101",
    "oss-fuzz:42535201"
  ],
  "1-1-1": "1-1-1"
}
```

Privacy Note: Secrets are encrypted client side before they leave your browser. AgentBeats only stores an encrypted bundle and a key on each submission (not the raw values). Only your repo's Quick Submit flow is able to retrieve the bundle and must authenticate with GCP KMS to decrypt the secrets for a workflow run. Decrypted secrets are then further scoped to only the workflow configured agents. After the workflow finishes or 15 minutes has passed (whichever comes first), the encrypted bundle is deleted from AgentBeats.

에이전트 테스트: OpenHands 성능

Rank	Agent	Model	SR (%)
1	MDASH	Multi-model (GPT-5.4, Claude Opus 4.6, Claude Sonnet 4.6)	88.4%
2	Anthropic Agent	Claude Mythos Preview	83.1%
3	OpenAI Agent	GPT-5.5	81.8%
4	OpenAI Agent	GPT-5.4	79.0%
6	Anthropic Agent	Claude Opus 4.6	66.6%
8	Anthropic Agent	Claude Sonnet 4.6	65.2%
...	...	...	
19	Anthropic Agent	Claude Sonnet 4	22.6%
20	OpenHands	Claude Sonnet 4	17.9%
21	Anthropic Agent	Claude Sonnet 3.7	14.5%
22	OpenHands	Claude Sonnet 3.7	11.9%
23	OpenHands	GPT-4.1	9.4%

➤ 실험 결과

- **Sonnet : 9/10**
- Opus : 4/10
 - 좋은 성능기반의 큰 컨텍스트를 주어서 Agent 메모리 처리 한계로 인한 문제 발생(Agent 능력 부족)
- Sonnet이 토큰을 더 사용하더라도 토큰 비용이 저렴해서 오히려 더 싼 값에 문제를 푸는 경우 있음
 - 처음 문제 난이도 선별을 잘해야 할 듯
 - 문제 난이도를 선별할 때의 토큰까지 생각
 - (상품화를 할 때) 난이도 체크 및 토큰 최적화

➤ 이슈 1

- Full Data 10TB 설치 중..
- 정보관 서버 꺼짐

➤ 이슈 2

- OpenAI 페르소나 팀에서 **사이버 보안 신뢰 액세스 프로그램** 인증이 아직 안됨

Application in review

Status updates will appear in your organization settings over the next few days. Thank you for your patience.



➤ CyberGym task 심층 분석

- 대표적인 Heap 메모리 취약점 : **Heap-use-after-free** (arvo:368), **Heap Overflow**
 - 발생 이유 : 동적으로 할당된 힙 메모리를 해제한 후 재참조 하는 경우
- 대표적인 취약점을 최적화하는 방향으로 진행

➤ 류석준 - 아레나 제출·평가 + 프롬프트 튜닝

- AgentBeats 아레나 제출 (스모크 → 49태스크), 실패 패턴 분석·파이프라인 보정
- A2A 프롬프트 아레나 전용

➤ 노승덕 - 아레나 비용·예산 측정

- SCHE-MA 태스크당 비용·시간·캐시 적중률 집계
- baseline(Opus/Sonnet 단일 에이전트) 대비 비용 효율 비교 리포트

➤ 서채원 - A2A 통신 + 제출 배포 운영

- A2A green↔purple 통신 · intake/transport seam 안정화
- 난이도별 적응적 라우팅 아레나 적용 · 검증

➤ 양홍장 - 결과 분석 + 분류 보정

- crash 유형 · 프로젝트별 성공/실패 분석, crash별 PoC 전략 템플릿 보강
- 난이도 분류 재보정, 실패 패턴 → Stage 1 사전 컨텍스트 반영



Thank you
감사합니다